RELATÓRIO - Atividade PLN

A tarefa foi realizada de forma individual por Carlos Eduardo Souza Oliveira. O código se baseia em um sistema de menu, no qual o usuário pode realizar operações do tipo de Processamento de Linguagem Natural em um texto, nesse caso sendo o texto escolhido os capítulos do 1 ao 5 do livro Dom Casmurro, de Machado de Assis.

A aplicação consiste em dois arquivos .py, um para a parte principal da execução e outro para as funções, além de dois arquivos .txt, um para o texto que será processado e analisado e outro que contém as principais stopwords da língua portuguesa. O texto principal tem suas palavras separadas inicialmente pelas pontuações e com auxílio do módulo “re”, as stopwords são separadas simplesmente com o método .split().

O usuário é então apresentado a 5 opções, sempre sendo feito o tratamento da leitura de input para ele não escolher opções inexistentes.

Na primeira opção, mostrar quantidade de palavras, é simplesmente usado a função “len” para descobrir o tamanho da lista que as guardam.

Na segunda, remover stopwords e mostrar dados estáticos, é usada uma função que pega o vetor de palavras e cria outros dois a partir dele, um apenas com as stopwords e outro com o resto, sendo ambos guardados para serem posteriormente utilizados, além de serem feitos cálculos para mostrar a quantidade de cada tipo e a porcentagem que representam do total.

Na terceira, mostrar as top(k) palavras mais frequentes, primeiramente pergunta-se ao usuário se ele quer incluir as stopwords nessa classificação, então uma função associa cada termo a sua frequência, usando um dicionário para isso, e, depois, pega-se essas frequências, ordena-as de forma invertida, pega-se as k maiores frequências, e então se procura no dicionário quais palavras tem os valores selecionadas, incluindo as que têm os mesmos, pois por exemplo, se duas palavras compartilham o pódio de terceira mais frequentes, não faz sentido escolher aleatoriamente apenas uma delas para mostrar. A operação de calcular a frequência de cada termo fica numa função separada desse resto, pois ela é usada individualmente depois.

Na quarta opção, imprimir os Hapaxes Legomenos (palavras de frequência única), simplesmente escolhe-se do dicionário de frequências aquelas com valor 1. Nesse caso, o dicionário é criado novamente, para que essa opção não seja dependente da anterior, onde ele é criado, para se realizar.

Na quinta e última opção de operação, foi usada a biblioteca “matplotlib”, mais especificamente seu módulo “matplotlib.pyplot”, para criar e mostrar um gráfico com a Curva de Zipf e os Cortes de Luhn. Inicialmente, ordena-se o dicionário de frequências com base da maior para a menor, depois cria-se o eixo x, com as palavras, e o eixo y, que representa a frequência de cada uma. O primeiro corte de Luhn é colocado com base na

quantidade de stopwords únicas do texto, pois ele deve ser usado para separá-las e descartá-las posteriormente, o segundo é feito no momento em que começam a aparecer as palavras de frequência única. Por questões de visualização, nem todas as palavras podem estarem escritas ao mesmo tempo no eixo x, então elas só aparecem de 15 em 15, baseado na posição delas na lista de frequências.